

Curriculum by *Active Inference* for Verifiable Environments

用期望自由能选择训练难度

温力成 · 程练 · 包煜 ——— ProRL-1.5B-v2 · 1× H200

01 背景 *Background*

GRPO/DAPO 以一组 K 个 rollout 为单位更新。一组全对 / 全错 $\rightarrow$ 组内零方差 $\rightarrow$ 梯度为 0。「有对有错」的概率 $U_K(p) = 1 - p^K - (1-p)^K$ 在 $p = \frac{1}{2}$ 取最大。RLVE [arXiv:2511.07317] 用「 $\text{acc} \geq 0.9$ 才升一档」决定课程 —— 工作点偏高、信号偏弱、只升不降。

方法	升档触发	工作点 P	U_K ($K=4$)	梯度信号	课程动态
RLVE-90 baseline	$\text{acc} \geq 0.9$	$\sim 0.7 - 0.9$	0.57	弱	只升
Signal-RLVE	$\min -\log U_K$	0.50	0.94	最强	可升可降
► FEP-RLVE	$\min G(d)$	0.50 + info	0.94	最强 + 探索	可升可降

02 想法 *Idea*

把「选哪个难度训练」重述为 *Active Inference* 的行动选择：最小化 期望自由能 $G(d)$ —— 同时拿到「偏好风险（让一组有对有错）」与「信息增益（弄清模型能力）」两项。难度自动贴着能力前沿。



03 怎么做 *Method*

$$G(d) = \lambda_{\text{pref}}(-\log U_K(\hat{p})) \text{ 实用} - \lambda_{\text{info}} I(s;o|d) \text{ 认知} + \lambda_{\text{cost}} C(d) \text{ 代价}$$

$$\pi(d) \propto \exp(-G(d) / T)$$

$\hat{p} = E_q[\sigma(a(s-d))]$	预测成功率（IRT 似然）
U_K	一组 K 个 rollout 「有对有错」的概率
$I(s;o d)$	对能力信念 $q(s)$ 的信息增益
T	温度： $T \rightarrow 0$ 贪心， $T \rightarrow \infty$ 均匀探索

FEP-RLVE Algorithm

Require: 能力信念 $q_\theta(s)$; λ_{pref} λ_{info} λ_{cost} T , K

```
1 repeat
2   采样环境  $e$ 
3   for  $d = d_{\min} \dots d_{\max}$  do
4      $\hat{p} \leftarrow E[\sigma(a(s-d))]$ 
5      $U \leftarrow 1 - \hat{p}^K - (1-\hat{p})^K$ 
6      $I \leftarrow H[\text{Ber}(\hat{p})] - E_S H[\text{Ber}(\sigma(a(s-d)))]$ 
7      $G \leftarrow -\lambda_{\text{pref}} \log U - \lambda_{\text{info}} I + \lambda_{\text{cost}} C$ 
8   end for
9    $d \sim \text{softmax}(-G(\cdot)/T)$ 
10  rollouts  $\leftarrow \pi_d$ ;  $r \leftarrow \text{verify}$ 
11   $\theta \leftarrow \text{GRPO-update}(\text{rollouts}, r)$ 
12   $q_\theta(s) \propto q_\theta(s) P(o|s,d)$ 
13 until
```

- 逐档估 EFE
- 预测成功率
- 有效率
- 信息增益
- EFE
- 可升可降
- RL 内核不变
- 贝叶斯更新
- 训练结束

04 结果 & 分析 *Results*




Fig 1. 组成成功率 p vs 训练步。RLVE-90 早期 0.6–0.7（太易、低信号）；Signal / FEP 全程贴近 0.5 信号最优带。




Fig 2. Held-out reward, Signal-RLVE 提升 +0.11 最大；FEP +0.03 次之；RLVE-90 几乎不动。

ARM	MEAN P	LAST-5 P	HELD-OUT 前 → 后	Δ
RLVE-90	0.552	0.519	-0.91 → -0.89	+0.02
► Signal-RLVE	0.491	0.444	-0.92 → -0.81	+0.11
FEP-RLVE	0.477	0.531	-0.91 → -0.88	+0.03

ANALYSIS · 关键观察

- 训练成功率最高的不是泛化最好的。RLVE-90 训练 p 最高（0.55）但 held-out 几乎不动。
- 对准 ½ 信号最优带是有用的：Signal-RLVE 提升 +0.11，是 RLVE-90 的 5x 以上。
- EFE 的认知项需要时间：FEP-RLVE 同样改善（+0.03），其信息增益项在 30 步 / 60% 截断下尚未完全体现。
- RL 内核与算力开销几乎不变：只增加 $O(\text{难度数})$ 的 CPU 计算。