

FEP-RLVE: *Expected Free Energy* Difficulty Control for Verifiable Environments

程 练 包 煜 温 力 成

背景

RLVE

现有 RLVE 以验证正确率阈值驱动难度递增，但该准则将任务完成率近似为训练价值，忽略了 rollout 组内奖励方差对策略梯度的决定作用。

在 RLVE 中，每个环境维护一个难度上界；当最近的验证正确率超过阈值时，上界单调上移。这类难度控制规则隐含假设是“高正确率意味着应当升难”。然而 GRPO/DAPO 的有效更新依赖 rollout 组内的奖励差异；当一组样本全对或全错时，优势估计退化，prompt 对 policy gradient 的边际贡献显著下降。

$$U_K(p) = 1 - p^K - (1 - p)^K$$

K = 4 时， $U_K(0.9) = 0.344$ ，而 $U_K(0.5) = 0.875$

因此，固定阈值策略存在两个结构性偏差：其一， $\text{acc} \geq 0.9$ 偏向低方差高成功率样本；其二，单调升难缺乏基于观测的回退机制。

自由能原理

自由能原理（Free Energy Principle, FEP）是 Karl Friston 提出的信息物理与认知科学框架，用于解释自组织系统如何在与环境耦合时维持稳定状态。其基本观点是：系统通过内部生成模型预测感觉输入，并最小化 surprisal，即观测的负对数概率，或其变分上界。

在贝叶斯表述中，系统不能直接访问产生观测的隐藏状态，只能以近似后验 $q(s)$ 表示对隐藏原因的信念；生成模型 $p(o,s)=p(o|s)p(s)$ 则描述隐藏状态如何生成观测。最小化自由能可被理解为提高预测准确性、约束模型复杂度，并通过 active inference 将感知更新与行动选择统一起来。

$$\begin{aligned} F(q) &= E_q[\log q(s) - \log p(o,s)] \\ &= D_{KL}(q(s) \parallel p(s \mid o)) - \log p(o) \geq -\log p(o) \end{aligned}$$

s	隐藏状态：在本文中对应环境级 latent competence。
o	观测：在 RLVE 中是验证器返回的 correct/wrong。
q(s)	环境难度控制器维护的能力信念，实际写作 $q_e(s)$ 。
p(s o)	观测后的真实后验：自由能最小化使 $q(s)$ 向它靠近。
F(q)	surprise $-\log p(o)$ 的可优化上界，越低表示信念与观测越一致。

自由能推导

下图为自由能示意图与简单推导。



从自由能视角重写 RLVE 难度选择

我们将环境难度控制器表述为 environment-level active-inference controller：隐藏状态是模型能力，行动是选择题目难度，观测是验证器的 correct/wrong。

自由能概念	在 RLVE 中的含义
隐藏状态	模型在环境 e 上的 latent competence，不能直接观测，只能由验证器反馈推断。
观测	给定难度后，rollout 被验证器判定为 correct/wrong。
行动	为下一批题目选择候选难度，而不是由固定阈值单调推进。
偏好	偏好非退化 rollout 组，即组内同时出现 correct 与 wrong，从而保留优势估计。
目标	选择低偏好风险、高信息增益、低成本的难度。

控制循环：依据能力后验评估候选难度，按低期望自由能采样行动，并用验证器观测执行贝叶斯更新。

读取信念	预测成功率	计算自由能	选择难度	更新后验
为每个环境维护 latent competence 后验。 $q_e(s)$	由 IRT 风格似然估计 correct 概率。 $\hat{p}_e(d) = E_{s \sim q_e} \sigma(a(s - d))$	联合偏好风险、信息增益与成本项评分。 $G_e(d) = \lambda_{\text{sig}}(-\log U) - \lambda_{\text{info}}I + \lambda_{\text{cost}}C$	依据 Boltzmann policy 从候选难度中采样。 $\pi(d \mid e) \propto \exp(-G_e(d) / T)$	将验证器输出作为观测更新后验。 $q_e(s) \leftarrow q_e(s) \cdot P(o \mid s, d)$

框架、伪代码与训练参数

实现层面，FEP-RLVE 作为 RLVEManager 的可替换环境难度控制器：保留 Gym 环境、验证器与 GRPO 内核，仅修改题目生成前的难度选择，以及 rollout 后的能力后验更新。

表 1 FEP-RLVE 难度控制算法

Algorithm 1: Environment-Level Difficulty Controller

Input: 环境集合 E、候选难度集合 D_e 、rollout 组大小 K，后验 $q_e(s)$ ，观测 o，权重 $\lambda_{\text{sig}}, \lambda_{\text{info}}, \lambda_{\text{cost}}$ ，温度 T。
Output: 采样难度 d_t 与更新后的后验 $q_e(s)$ 。

```
1 for training iteration t = 1, ..., N do
2   sample environment e ~ E and read belief q_e(s)
3   for each candidate difficulty d ∈ D_e do
4     p_d ← E_{s~q_e} σ(a(s - d)) success probability
5     U_d ← 1 - p_d^K - (1 - p_d)^K valid-signal score
6     q_d^1(s) ← norm[q_e(s)P(o=1 | s,d)]
7     q_d^0(s) ← norm[q_e(s)P(o=0 | s,d)]
8     I_d ← p_d D_KL(q_d^1 || q_e) + (1-p_d) D_KL(q_d^0 || q_e)
9     G_d ← λ_sig[-log U_d] - λ_info I_d + λ_cost C_e(d)
10  end for
11  d_t ~ softmax(-G_d / T); generate task and collect O_t = {o_{t,k}}
12  update policy with GRPO rewards from verifier outcomes
13  q_e(s) ← norm[q_e(s) ∏_k P(o_{t,k} | s,d_t)]
14 end for
```

表 2 实验设置与超参数

项	设置
groups	RLVE-90 作为 baseline；Signal-RLVE 与 FEP-RLVE 作为对比组。
training	4 envs; 30 rollout steps; all groups share the same training budget.
samples	K = 4; rollout batch = 8; oversample = 8; used for valid-signal score.
controller	$\lambda_{\text{sig}} = 1$; $\lambda_{\text{info}} \in \{0, 1\}$; T = 0.25; $\lambda_{\text{info}} = 0$ gives Signal-RLVE.
budget	response length = 2048.
evaluation	held-out eval at steps 0, 9, 19, 29.

结果分析与不足


结果：Signal-RLVE 在 held-out reward 上取得最大提升，说明将难度控制对准有效优势信号是有价值的；RLVE-90 虽保持较高训练正确率，但泛化改善有限，支持“高正确率不等于高训练价值”的判断。

不足：完整 FEP-RLVE 暂未超过 Signal-RLVE，主要受短训练预算、response truncation 偏高和单标量能力信念限制；当前还将各环境独立建模，难以表达跨环境共享技能、任务相关性和迁移效应。


后续：延长训练并降低截断率后，进一步调研联合环境 belief、层级 skill belief、跨环境共享先验与多维能力状态；将环境级 posterior 从独立标量扩展为可共享、可迁移的 skill graph，以检验信息增益项在长程训练中的收益。

结果

受限预算实验表明，较高训练成功率并不必然转化为更强泛化；直接对准有效信号带的 Signal-RLVE 获得最大 held-out 改善。



训练成功率：RLVE-90 更高，但未对应最佳 held-out 表现。



held-out reward：Signal-RLVE 在后期获得最大提升。

RL 难度策略	训练正确率均值 mean p	valid-signal score U_K	最终泛化表现 held-out reward	相对初始提升 Δ
RLVE-90	0.552	0.853	-0.891	+0.016
Signal-RLVE	0.491	0.852	-0.813	+0.109
FEP-RLVE	0.477	0.850	-0.875	+0.031